拥抱未来语言Rust|第二回 第一性原理看类型系统

原创 三角兽 三角兽 2024-03-14 12:05 四川

如何为各位看官呈现一篇既有深度又浅显易懂,还不落俗的关于类型系统的文章。思考许久,终于找到切入点,决定带大家从上帝视角审视通用类型系统,避免陷入某个特定语言的实现细节。在此,用"5 Why"法,去探寻类型系统的"第一性原理"。

------ 10个追问 ------

第一问:什么是类型系统?

答:是编程语言中的一个组成部分,它定义了语言中数据的类型,以及这些类型之间的操作规则。

第二问: Rust、Java、Python、汇编等几乎所有计算机语言为什么需要类型系统?

答: 类型系统用于区分不同的数据种类,确保类型的正确性。

第三问:为什么需要区分不同的数据种类?

答:编译阶段,类型检查保证类型安全;运行阶段,CPU需要知道一定的信息,才能正确地执行机器指令,而这信息隐藏在编译结果产生的操作码中的。例如读写某个变量,需要确定读写的长度和对应内存的位置。在语言层面,数据类型对应着长度,变量的名称对应着内存的位置。

第四问: 为什么CPU的执行需要确定操作码?

答:因为不同的操作码,对应着CPU中不同的的物理逻辑电路,例如+和-操作,对应着全加电路;*和/对应着乘法电路和除法电路。

第五问: 为什么会有逻辑电路?

答:因为实现计算机的基础是逻辑电路,而逻辑电路的理论基础是布尔逻辑,它是逻辑学的一个分支。

第六问: 什么是逻辑?

答:逻辑是一种用于分析和评估论证或推理的形式化体系,通常由命题及命题之间建立的推理关系组成

第七问: 什么是命题?

答:通常形式是,用于判断客观或主观事实是否成立的陈述语句,由这些语句组成命题。通过判断命题的真假,形成推理,构成逻辑。从这个角度讲,逻辑能力就是将事实从模糊中分离出来,进行真假判断或推理的能力。

第八问: 什么语言(这里指人类的语言)?

答:语言是沟通的桥梁,它起源生物群体对客观事实的心理描摹所形成的"观念",这些"观念"在群体中需要传播和交流,于是在群体中达成共识,形成了最初的语言。

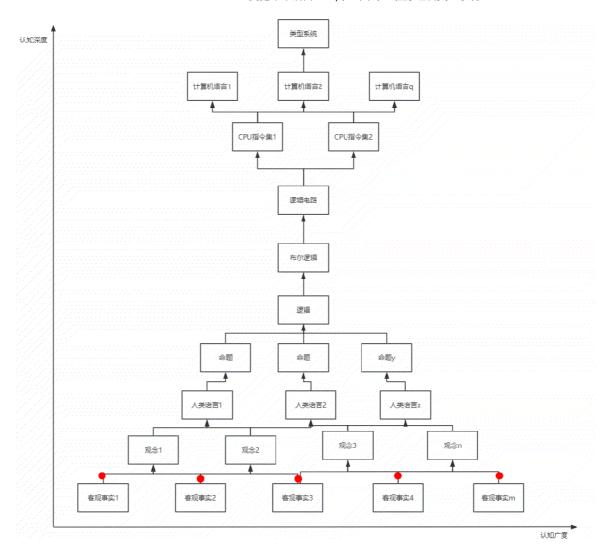
第九问: 什么是客观事实?

答:世界本来就存在的东西。例如,这个世界存在"猫"这个事实,经过人类的"心理描摹",有了"猫"的"观念",群体之间需要进行沟通和交流,于是有了"猫"这个词语,词语的组合就形成了语言,但语言不一定就是有逻辑的语言,经常听到毫无逻辑的言论,就是这个意思。语言形成命题,组成逻辑链。再到后面的布尔逻辑,逻辑电路,计算机编程语言,及类型系统,是不是就连起来了。

第十问:我还是别问了, 哈哈哈。

"5 Why"法不一定要5个Why,只要获取到想要的答案就可以停止了,上面其实到第四问就可以停止了,因为已经知道类型系统是干什么以及为什么需要类型系统。

类型系统是整个人类认知体系扩充的必然产物, 咳咳咳, 绕得有点远了, 踩刹车。



----- 我准备要讲的类型系统 -----

Rust拥有最复杂的类型系统,没有之一,比我学过的Scala的类型系统还复杂(这也是很多人从入门到放弃的原因之一),不信请看下面的脑图(图太长,做成了滚动动画:))。别说图了,人看完都糊了,哈哈哈。



我不打算按脑图来讲,不然会被喷,内容太多显得很啰嗦,安排的60回根本就写不完,即便 能写完也猴年马月去了,哈哈哈。

咱们基于"**第一性原理**",推导和理解Rust的类型系统(其实对所有语言是通用的),大部分类型及其意义是可以演绎出来的(学原理的重要性)。

----- 推导出类型系统 -----

前面提到了,类型系统是人类认知发展的必然产物,不同计算机语言拥有的类型系统,其底层对应的"第一性原理"应该是类似的,接下来我们就推导一套最简单的类型系统。

4EH FH 12H EH 7AH DH **FEH** CH Word at Address BH Doubleword at Address AH Contains FE06H Contains 7AFE0636H 06H BH 36H AH Byte at Address 9H 1FH 9H Contains 1FH Quadword at Address 6H A4H **8H** 7AFE06361FA4230BH 23H 7H Word at Address 6H Contains 230BH **OBH 6H** 5H 45H 67H 4H Word at Address 2H 74H **3H** Contains 74CBH Double quadword at Address OH **CBH** 2H Word at Address 1H Contains Contains CB31H 31H 1H 4E127AFE06361FA4230B456774CB311a 12H OH ¥ 🗫 公众号・三角兽

----- 认识内存 -----

内存可以看做是一个按最小单元为1字节划分的表格,下方是低地址,上方是高地址。按内容的存放方式,可分为小端字节序和大端字节序。小端字节序是指数值的低位存储在内存低地址;大端字节序指数值的低位存储在内存的高位地址,按此规则,上图是小端字节序存储的。

按内存为4Gb计算。这个表格拥有4 * 1024 * 1024 * 1024个存储单元,数量是相当庞大的,为了简化推理,假设我们内存容量为20字节,画成表格就是20个单元格,单元格里面使用十进制数字表示内存地址。

0	1	2	3	4	5	6	7	8	9
10	11	12	13	14	15	16	17	公炊号	・三角兽

假定现在还没有语言规范,也没有类型系统,描述对内存单元的存取操作,例如往19号格子 存入88,往4号格子存入99,如何做呢?

0	1	2	3	99	5	6	7	8	9
10	11	12	13	14	15	16	16 /2	众姆·	三角磐

基于这种需求,设计指令,如下:

mov \$88 (19) mov \$99 (4)

这两条指令表示:

往19号格子 存入数字88 往4号格子 存入数字99

这里需要注意,每一个单元格的大小是一个字节,即8位,能够表示的数字范围如果是有符号的话,为-128 ~ 127,如果为无符号位为0 ~ 256区间。

如果有一个需求,需要存储1024,怎么办?很显然,一个格子存不下,那我们就用两个格子。

0	1	2	3	99	5	6	7	8	9
10	11	12	13	14	15	10)24 % /	· 鲁众公	= 88≜

如果要存储我的工资4294967291怎么办呢?哈哈,过于夸张了。那我就用四个格子呗。

0	1	2	3	99	5	6	7	8	9
10	11		4294967291)24 🦡	公众号	一 灣兽

此时,前面的汇编语法就得重新设计了,指令需要表明占用的字节数和数据类型。对于占用一个字节的整数,我们用movb表示,对于占用两个字节的整数,我们用movw表示,对于占用四个字节的整数我们用movl表示,以此类推可以设计出更多的指令。

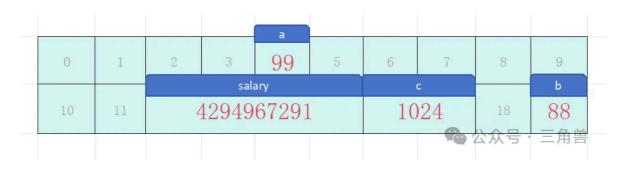
movb \$88 (19) movb \$99 (4) movw \$1024 (16) movl \$4294967291 (12)

对应着如下的描述:

往19号格子 存入数字 88 ,占用1个字节 往4号格子 存入数字 99 ,占用1个字节 往16号格子 存入数字 1024 ,占用2个字节 往12号格子 存入数字 4294967291 ,占用4个字节

不知不觉,类型系统就有了一个雏形。但是还有优化的地方,对于高级语言,肯定是不能直接指定内存地址的,都是用一个标号替代具体的内存地址,高级语言中定义的变量在编译链接阶段,被转换为虚拟内存地址,经过MMU内存管理单元最终转换为真实的物理内存地址。

回过头看上面的表格,现在我们的内存已经显得非常凌乱了,还能记起来12号格子存的什么 内容吗?那下面我们来优化类型体系,给类型体系加上一个标签试一试。用标签表示格子位 置,这样就不用记住那些无意义的格子编号了。



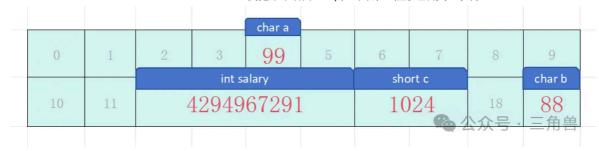
有了标签之后,往格子里面存储数据就不用指定内存网格地址了,高级语言在编译阶段,会将"标签"转换为虚拟地址,最终映射到真实的物理内存上,经过"标签"的抽象,使得程序员无需关心底层具体内存地址的细节,不得不说,真是一个伟大的发明。

那上面定义的汇编又可以改一改了。

movb \$88 b
movb \$99 a
movw \$1024 c
movl \$4294967291 salary

程序员只管定义"标签"(高级语言里面的变量),剩下的就是编写计算逻辑,后面的事儿就交给编译器了(编译器可真累)。至此我们完成了数据的存储,通过定义标签和定义的指令,知道将值存储到内存的哪个位置和占用多少字节。那反过来,如果我们要取出刚刚存入的salary标签的值,怎么做呢?

具体的描述应该是,找到salary标签所在的内存地址并取出四个字节返回,标签对应了内存地址,但怎么确定要取回几个字节呢?显然我们的类型系统还需要一个"标识",用于指明一次性操作几个字节,没错这就是高级语言里面的类型了,例如int, byte等。



带类型带标签的写法,其实就是和大多数高级语言类似的语法了,下面是C语言的写法。

```
char a = 99;
char b = 88;
short c = 1024;
int salary = 4294967291;
```

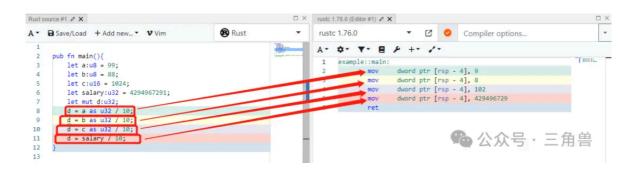
而对于Rust,写法也是类似的:

```
let a:u8 = 99;
let b:u8 = 88;
let c:u16 = 1024;
let salary:u32 = 4294967291;
```

借助在线工具[Compiler Explorer]

```
https://godbolt.org
```

可以方便地看到Rust和编译后汇编语言的对应关系。



高级语言中定义的变量其实是给程序员看的,CPU执行的时候变量已经变成地址了,类型也会变成具体的操作指令。在高级语言中的类型系统比我们定义的"初级系统"复杂和丰富得多,涵盖整型、浮点型、布尔类型、字符类型、数组、元组、结构体、枚举、trait特征、泛型、集合、裸指针及智能指针等等。

不知不觉,我们已经进入到了Rust的类型系统了,哈哈哈。后面几个回合,我打算挑重点来写,因为学会了重点,其它都是可以演绎的。

另外文章里面也不打算嵌入过多的代码,在我看来非常影响排版和浏览体验,只会贴出关键 代码并加以注释,所有的项目代码,可以点击"阅读原文"进入GitHub查看,代码中的注解更 详细哦,大家顺手点个星,来个**"一键三连"**就是对我最大的鼓励和支持,兽兽在此感谢各位看官了。

------ 关于本系列 ------

本系列的开篇词看这

三角兽新系列! 拥抱未来语言Rust

番外篇看这里

拥抱未来语言Rust|番外篇 我的成长故事

前面的基础章节看这里

拥抱未来语言Rust|第一回 环境准备

更多的资料和项目源码可以点击**阅读原文**

最后,祝大家都能追更到系列结束,只要你敢持续追更,并且把每一回的内容搞懂,我就敢让你在系列结束后说一句,我对Rust很熟悉。

您的一键三连,就是我持续更新和走下去最大的动力,兽兽在此**鞠躬感谢!**

另外,本系列完全免费,希望大家能多多传播给同样喜欢的人!我们下回见。

#拥抱未来语言Rust 61 #技术的第一性原理 3

阅读原文

喜欢此内容的人还喜欢

震惊!对不起我要食言了~

三角兽

食言

ign Patterns

别找了, Rust设计模式都在这里了, 设计模式之工厂模式

三角兽



性能炸裂! 10万行数据耗时500毫秒,使用rust的nom框架实现时序数据库协议解析(下)



三角兽